

內容

1. 專案簡介	2
2. 實驗方法	2
2.1 數據集	2
2.2 分類器	3
2.3 實驗流程	3
3. 實驗結果與分析	4
3.1 Breast Cancer 數據集 (二元分類)	4
3.2 Banknote Authentication 數據集 (二元分類)	5
3.3 Digits 數據集 (多類別分類)	7
3.4 Dry Bean 數據集 (多類別分類)	8
4. 綜合結論	9
附錄	10
程式碼架構	10
環境建立與如何運行	11
Main	11
classifiers	17
utils	19
evaluation	22
visualize	27
GitHub	32

1. 專案簡介

本研究旨在對三種基礎但具有代表性的機器學習分類器——K-近鄰演算法 (KNN)、隨機森林 (Random Forest) 和支持向量機 (SVM)——進行系統性的性能評估。為了全面地測試這些模型，選用了四個來自 UCI 機器學習庫和 Scikit-learn 的公開數據集，涵蓋了二元分類與多類別分類、不同樣本規模及特徵維度的場景

本報告將詳細闡述實驗的設計、流程、所採用的評估指標，並對實驗結果進行深入的分析與比較，以期得出各分類器在不同任務下的適用性與相對優劣

2. 實驗方法

2.1 數據集

選用了以下四個數據集進行實驗：

1. Breast Cancer Wisconsin (乳癌數據集):

- 類型：二元分類
- 任務：根據 30 個從乳房腫塊細針穿刺數位影像中計算出的特徵，判斷其為惡性或良性
- 特性：特徵維度較高，樣本數較少 (569 筆)

2. Banknote Authentication (鈔票鑑定數據集):

- 類型：二元分類
- 任務：根據從鈔票影像小波轉換中提取的 4 個特徵，判斷其為真鈔或偽鈔
- 特性：特徵維度低，分類邊界清晰

3. Digits Dataset (手寫數字數據集):

- 類型：多類別分類 (10 類)
- 任務：辨識 8x8 像素的手寫數字圖片(0-9)
- 特性：經典的多類別分類問題，特徵為 64 個像素值

4. Dry Bean Dataset (乾豆數據集):

- 類型：多類別分類(7 類)
- 任務：根據 16 種外觀形態特徵，將乾豆分為 7 個不同的品種
- 特性：樣本數最多 (約 13,611 筆)，類別較多，是本次實驗中最具挑戰性的數據集

2.2 分類器

1. K-Nearest Neighbors (KNN)：

一種基於實例的非參數演算法，一個樣本的類別由其最近的 K 個鄰居的類別投票決定

2. Random Forest (RF)：

一種集成學習方法，構建多個決策樹並將它們的預測結果進行集成（投票或平均），以獲得更準確、更穩定的預測，通常具有很好的抗過擬合能力

3. Support Vector Machine (SVM)：

一種強大的監督學習模型，其目標是找到一個能將不同類別的數據點以最大間隔 (margin) 分開的超平面透過 kernel trick，SVM 也能高效地處理非線性問題

2.3 實驗流程

1. 數據預處理

在訓練每個模型前，對數據進行了標準化(Standardization)處理，將所有特徵縮放到均值為 0、標準差為 1

此步驟被封裝在 Scikit-learn 的 Pipeline 中，以確保標準化的參數僅從訓練集學習，避免數據洩漏

2. 超參數優化

使用 GridSearchCV 搭配 **5-Fold Cross-Validation** 來為每個分類器在每個數據集上尋找最佳的超參數組合，搜索的參數網格如下：

- **KNN**：n_neighbors：[3, 5, 7]
- **Random Forest**：n_estimators：[50, 100, 200]
- **SVM**：C：[0.1, 1, 10], kernel：['linear', 'rbf']

3. 模型評估

◦ 主要指標

從 **5-Fold Cross-Validation** 中獲取每個最佳模型的平均準確率 (Accuracy)、平均精確率 (Precision-Macro)、平均召回率 (Recall-Macro) 和平均 F1-Score (Macro)


◦ 輔助指標

在保留測試集（一開始分割出去的那部分完全沒有參與訓練的 data）上計算 AUC (Area Under the ROC Curve) 分數，並生成混淆矩陣 (Confusion Matrix) 以進行更深

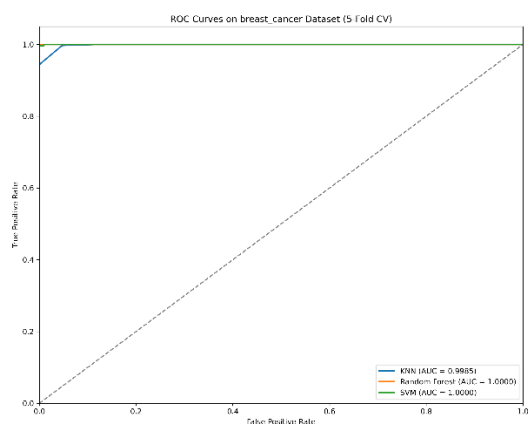

3. 實驗結果與分析

3.1 Breast Cancer 數據集 (二元分類)

在此數據集上，SVM 表現最為出色，特別是其線性核心 (`kernel='linear'`) 版本取得了最高的平均準確率和 AUC 分數




以下為使用各個分類器，在各自的最佳超參數下得到的混淆矩陣：



分析：線性 SVM 的勝出強烈暗示此數據集的特徵在經過標準化後，具有高度的線性可分性。KNN 和 Random Forest 也表現不俗，但 SVM 尋找最大間隔超平面的能力使其在此任務上略勝一籌



3.2 Banknote Authentication 數據集 (二元分類)

這是一個相對簡單的數據集，在 SVM 下曾在最佳超參數的配置下達到 100%的準確率



由於 AUC 本身評比的是預測分數排序是否完美，因此此處其他兩個分類器即使沒達到過 Accuracy=1，仍有 AUC=1 的分數

以下為使用各個分類器，在各自的最佳超參數下得到的混淆矩陣：



分析：此數據集的清晰可分性使得所有模型都表現優異。KNN 在此類低維度、結構清晰的問題上非常高效。SVM 同樣找到了完美的分類邊界。

補充：不過考慮到出現 $\text{accuracy} = 1$ 本身是一個不正常的跡象，因此此處我進行過一番檢查

1. test data 混入 train data

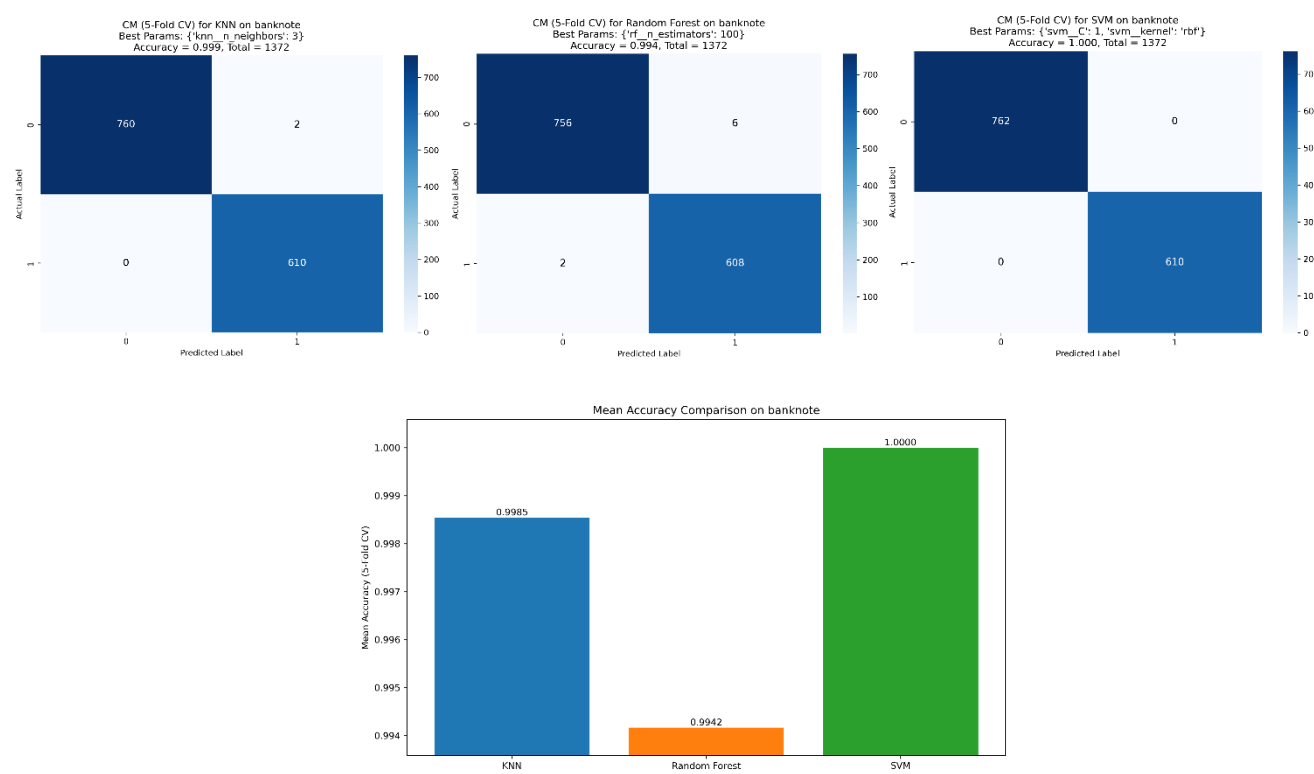
這是我首先懷疑的，不過經過檢查 test data 並沒有混入 train data

在程式中我使用的 `sklearn.model_selection` 的 `StratifiedKFold` 進行資料分割，所有的 dataset 用的都是同一套切割邏輯，但只有此數據集出現了 accuracy 為 1 的狀況


2. 更改初始化的 random seed

另一個可能就是運氣很好真的撞到了（不過考慮到驗證的時候也是以 **5-Fold Cross-Validation** 進行，其實不太可能）

因此我有嘗試更改種子為：`random_state=133`，結果仍舊完全一樣



3. 資料可視化




此處分別為資料集進行了 PCA 以及 LDA 的資料可視化。從 LDA 可以清晰地看出，紅色與藍色幾乎完全分開、中間重疊極少（幾乎沒有交錯區域）。也就是說，在這條線上模型可以找到一個分界點，使得兩類的機率分佈幾乎不重疊


這證明了 Banknote 是一個幾乎完美線性可分的資料集，對於 SVM 這種學習一個穩定的「超平面」或「平滑邊界」的分類器而言，很容易就能找到能幾乎將資料集完美分割的邊界。個人認為，這是 SVM 在此資料集上能多次達到 accuracy=1 的原因。

3.3 Digits 數據集 (多類別分類)

在手寫數字辨識這個多類別任務中，SVM 再次取得了最高的平均準確率和 AUC 分數。




以下為使用各個分類器，在各自的最佳超參數下得到的混淆矩陣：




分析：所有三個分類器都表現出了強大的多類別分類能力，準確率均超過 97%。SVM 透過其核函數技巧，在處理 64 維像素特徵時展現了其優越性。值得注意的是，200 棵樹的 Random Forest 表現也極具競爭力，顯示了集成方法的效率。

3.4 Dry Bean 數據集 (多類別分類)

所有模型的性能都非常接近，SVM 最終以微弱的優勢在 ACC 指標上勝出



以下為使用各個分類器，在各自的**最佳超參數**下得到的混淆矩陣：



分析：

在這個樣本量大、類別多的複雜問題上，模型之間的差距被縮小。SVM (C=10, kernel='rbf') 表現最好，說明一個經過良好調整的非線性 SVM 在處理複雜、高維且有大量數據的問題時是強大的工具。所有模型的 Accuracy 分數均在 0.92-0.94 之間，表明它們在所有 7 個類別上都有相當均衡的表現

另外，值得關注的是，這三種分類器的原理並不相同，但它們在這份資料集上的**混淆矩陣分佈**卻非常相似

在混淆矩陣裡，可以看到幾個固定的混淆現象：

- **DERMASON ↔ SIRA**

這兩種豆的物理形狀特徵最接近，模型常混淆，不管是距離（KNN）、樹分裂（RF）或超平面（SVM），都難以區分

- **BARBUNYA ↔ CALI**：

也是形狀或顏色類似的類別，屬於次要混淆對

- **BOMBAY：**

幾乎完美分類，表示這個類別的特徵分佈非常獨立、清晰

再考慮到此資料集的特徵多為形狀、大小、顏色、紋理等連續值特徵，加上部分類別之間（例如 DERMASON vs SIRA）本身在物理外觀上就有部分重疊，可以推論不論使用哪種模型，只要它能捕捉到主要特徵結構，分類邊界可能就會很接近

因此模型雖然不同，但它們學到的決策邊界其實都在相同的資料分佈結構上，錯誤樣本也會重疊

4. 綜合結論

經過搭建並執行了完整的分類器比較流程。所有實驗的詳細數值結果總結如下：

dataset	classifier	best_params	mean_accuracy	mean_precision	mean_recall	mean_f1_score	auc
breast_cancer	KNN	{'knn__n_neighbors': 3}	0.9665890389691041	0.9703585040690303	0.9590428228284436	0.9636588598824034	0.998520162782094
breast_cancer	Random Forest	{'rf__n_estimators': 100}	0.9560937742586555	0.9557435041160833	0.9526707402034947	0.9528924697936147	1.0
breast_cancer	SVM	{'svm__C': 10, 'svm__kernel': 'rbf'}	0.9789163173420278	0.9799307432106413	0.9754488819220232	0.9772669033859678	0.9999735743353946
banknote	KNN	{'knn__n_neighbors': 3}	0.9985401459854014	0.9983739837398374	0.9986842105263157	0.998523607462787	1.0
banknote	Random Forest	{'rf__n_estimators': 50}	0.9941632382216323	0.993840347916362	0.9944175872822525	0.9940963445153678	1.0
banknote	SVM	{'svm__C': 1, 'svm__kernel': 'rbf'}	1.0	1.0	1.0	1.0	1.0
digits	KNN	{'knn__n_neighbors': 5}	0.9788502011761064	0.9794170504000224	0.9788219648219648	0.9787964332704355	0.9998912440201753
digits	Random Forest	{'rf__n_estimators': 200}	0.979962859795729	0.9806820738182968	0.9798818734701088	0.9799519376359956	1.0
digits	SVM	{'svm__C': 10, 'svm__kernel': 'rbf'}	0.9838594862271742	0.9842239109963569	0.983882882882883	0.983836601552334	1.0
dry_bean	KNN	{'knn__n_neighbors': 7}	0.923959154917036	0.9382790896970314	0.9344295812705029	0.9361396611031605	0.9976572093025303
dry_bean	Random Forest	{'rf__n_estimators': 200}	0.9255020570679516	0.9379431626428717	0.9345859964132149	0.9361462875861128	1.0
dry_bean	SVM	{'svm__C': 10, 'svm__kernel': 'rbf'}	0.9315265530006316	0.9439156881279256	0.9411645795147809	0.942449483893051	0.9960355447330907

總體觀察：

- **SVM 是其中表現最好的分類器：**在所有四個任務中，經過超參數優化的 SVM 均取得了最佳或並列最佳的性能

這證明了它作為一個強大且靈活的 **baseline model** 的價值

- **沒有萬能模型：**

雖然 SVM 表現最好，但其他模型在特定場景下也極具競爭力

例如，KNN 在簡單問題上高效且準確；Random Forest 則提供了無需過多調參就能獲得的穩定、良好性能

- **超參數優化的重要性：**

這裡可能看不太出來，不過再我使用不同的種子碼（42、133）時，會出現能夠達到最佳表現的超參數組合出現變化的情況。這凸顯了超參數搜索對於發揮模型全部潛力的關鍵作用

- **部分 ACU 達到 1 的分數**

在實驗結果中可以觀察到，部分分類器（例如 KNN 與 Random Forest）在個別資料集上曾於某些訓練/驗證分割中達到 100% 的分類準確率，但其平均準確率（mean accuracy）仍略低於 1 這種現象屬於正常且可解釋的統計波動，並非程式錯誤或資料分割異常所造成

首先，本實驗採用 Stratified 5-Fold Cross Validation，確保每個 fold 的訓練與測試資料互斥且類別比例一致，並利用 Scikit-learn 的 cross_val_predict 在嚴格的資料隔離下生成預測結果，因此不存在資料洩漏的情況

導致部分模型於單次 fold 達到完美分類的主要原因有三點：

1. **資料特性：**如 Banknote Authentication 資料集具有高度線性可分性，在部分隨機切割下，訓練與測試樣本之間的邊界極為明確，導致分類器能完全正確預測
2. **模型隨機性：**像 Random Forest 含隨機抽樣與樹分裂過程，不同隨機狀態下可能出現局部完美分類。KNN 亦可能在某些資料分佈下，所有測試樣本剛好鄰近同類樣本
3. **AUC 指標特性：**AUC 反映的是模型對正負樣本排序的正確性，而非實際分類結果。即使模型在某些閾值下產生少量錯誤，只要分數排序完全正確，也可能得到 AUC=1.0

附錄

程式碼架構

- **main.py:** 主執行腳本，負責協調整個實驗流程，包括數據加載、模型訓練、超參數搜索和評估。
- **utils.py:** 工具模組，提供加載所有數據集的統一接口。
- **visualize.py：** 負責資料集的資料分佈視覺化（PCA、LDA）。
- **classifiers.py:** 分類器模組，封裝了所有分類器，並內建了數據標準化 Pipeline。
- **evaluation.py:** 評估模組，提供繪製混淆矩陣、ROC 曲線和性能比較長條圖的功能。
- **requirements.txt:** 專案的 Python 依賴包列表。
- **data/:** 存放本地數據集的資料夾。

- plots/: 存放所有生成圖表的資料夾。
- Readme.md: 本說明檔案，記錄專案細節與成果。

環境建立與如何運行

1. **安裝依賴:** 本專案的所有 Python 依賴都記錄在 requirements.txt 中。請運行以下指令進行安裝

```
pip install -r requirements.txt
```

2. **準備數據**

- Breast Cancer Wisconsin 數據集會自動從網路下載
- Banknote Authentication 需手動下載（放在 data 資料夾）：[UCI 連結](#)
- Digits Dataset 數據集會自動從網路下載
- Dry Bean Dataset 需手動下載（放在 data 資料夾）：[UCI 連結](#)

3. **執行實驗:** 所有實驗流程都已整合到 main.py 中。直接運行此腳本即可：

```
python main.py
```

腳本會自動執行所有數據集的超參數搜索、模型評估、生成所有圖表至 plots/ 資料夾、匯出 results_summary.csv。

Main

```
import numpy as np
```

```
import pandas as pd
```

```
import warnings
```

```
import os
```

```
from utils import load_dataset
```

```
from classifiers import BaseClassifierWrapper, KNeighborsClassifierWrapper,  
RandomForestClassifierWrapper, SupportVectorMachineWrapper
```

```
from evaluation import plot_confusion_matrix, plot_roc_curves, plot_metric_comparison
```

```
from sklearn.model_selection import GridSearchCV, StratifiedKFold, cross_val_predict
```

```
from sklearn.metrics import accuracy_score, roc_auc_score, confusion_matrix
```

```
from visualize import visualize_pca, visualize_lda
```

```
warnings.filterwarnings("ignore", category=UserWarning)
```

```
def main():
```

```
    """主函式：使用 5-Fold Cross Validation 執行所有數據集的模型搜尋與評估"""
```

```
    os.makedirs('plots', exist_ok=True)
```

```
    dataset_names = ['breast_cancer', 'banknote', 'digits', 'dry_bean']
```

```
    final_results = []
```

```
    for dataset_name in dataset_names:
```

```
        print(f'\n{'='*50}')
```

```
        print(f'處理數據集: {dataset_name}')
```

```
        print(f{'='*50}')
```

```
        # === 載入資料 ===
```

```
        X, y = load_dataset(dataset_name)
```

```
        visualize_pca(X, y, dataset_name)
```

```
        visualize_lda(X, y, dataset_name)
```

```
        if X is None:
```

```
            continue
```

```
        is_binary = len(np.unique(y)) == 2
```

```
        # === 參數設定 ===
```

```
        param_grids = {
```

```
            "KNN": {'knn__n_neighbors': [3, 5, 7]},
```

```

"Random Forest": {'rf__n_estimators': [50, 100, 200]},

"SVM": {'svm__C': [0.1, 1, 10], 'svm__kernel': ['linear', 'rbf']}

}

classifiers = {

    "KNN": KNeighborsClassifierWrapper(),

    "Random Forest": RandomForestClassifierWrapper(random_state=42),

    "SVM": SupportVectorMachineWrapper(random_state=42)

}

roc_results_for_dataset = []

metrics_for_dataset = {'Accuracy': {}, 'AUC': {}}

# === Cross-validation 分割設定 ===

cv = StratifiedKFold(n_splits=5, shuffle=True, random_state=42)

for name, clf_wrapper in classifiers.items():

    print(f"\n--- 為 {name} 執行 5-Fold Cross Validation on {dataset_name} ---")

    scoring = {

        'accuracy': 'accuracy',

        'precision': 'precision_macro',

        'recall': 'recall_macro',

        'f1_score': 'f1_macro'

    }

    # GridSearchCV for parameter tuning

```

```

grid_search = GridSearchCV(
    clf_wrapper.model,
    param_grids[name],
    cv=cv,
    scoring=scoring,
    refit='accuracy',
    n_jobs=-1
)

grid_search.fit(X, y)

best_model = grid_search.best_estimator_

print(f'找到的最佳參數: {grid_search.best_params_}')

# Cross-validation 預測（用於 Confusion Matrix & ROC）

y_pred = cross_val_predict(best_model, X, y, cv=cv)

y_proba, _ = BaseClassifierWrapper._get_scores(best_model, X)

# === 平均 CV 結果 ===

mean_accuracy = grid_search.cv_results_['mean_test_accuracy'][grid_search.best_index_]
mean_precision = grid_search.cv_results_['mean_test_precision'][grid_search.best_index_]
mean_recall = grid_search.cv_results_['mean_test_recall'][grid_search.best_index_]
mean_f1 = grid_search.cv_results_['mean_test_f1_score'][grid_search.best_index_]

auc_score = None

if y_proba is not None:
    if is_binary:
        auc_score = roc_auc_score(y, y_proba[:, 1])

        roc_results_for_dataset.append((y, y_proba[:, 1], name))

```

```

else:

    auc_score = roc_auc_score(y, y_proba, multi_class='ovr', average='macro')

    print(f'平均 CV 準確率: {mean_accuracy:.4f}, 精確率: {mean_precision:.4f}, 召回率: {mean_recall:.4f}, F1: {mean_f1:.4f}')

    if auc_score is not None:

        print(f'整體資料 AUC: {auc_score:.4f}')

    final_results.append({

        'dataset': dataset_name, 'classifier': name,

        'best_params': str(grid_search.best_params_),

        'mean_accuracy': mean_accuracy,

        'mean_precision': mean_precision,

        'mean_recall': mean_recall,

        'mean_f1_score': mean_f1,

        'auc': auc_score

    })

    metrics_for_dataset['Accuracy'][name] = mean_accuracy

    if auc_score is not None:

        metrics_for_dataset['AUC'][name] = auc_score

# === 繪製混淆矩陣 ===

cm = confusion_matrix(y, y_pred)

cm_title = f'CM (5-Fold CV) for {name} on {dataset_name}\nBest Params: {grid_search.best_params_}'

cm_save_path = f'plots/CM_{name}_{dataset_name}.png'

plot_confusion_matrix(y, y_pred, title=cm_title, save_path=cm_save_path)

```

```

# === 繪製 ROC 與比較圖 ===

if is_binary:

    plot_roc_curves(roc_results_for_dataset, title=f'ROC Curves on {dataset_name} Dataset (5-
Fold CV)',

                    save_path=f'plots/ROC_{dataset_name}.png')

    plot_metric_comparison(metrics_for_dataset['Accuracy'], metric_name='Mean Accuracy (5-Fold
CV)',

                            title=f'Mean Accuracy Comparison on {dataset_name}',
save_path=f'plots/ACC_BAR_{dataset_name}.png')

    if metrics_for_dataset['AUC']:

        plot_metric_comparison(metrics_for_dataset['AUC'], metric_name='AUC Score',

                                title=f'AUC Score Comparison on {dataset_name}',
save_path=f'plots/AUC_BAR_{dataset_name}.png')

# === 匯出結果 ===

print(f'\n\n{'='*50}')

print("所有實驗已完成 - 匯出結果摘要")

print(f'{'='*50}')

results_df = pd.DataFrame(final_results)

results_df.to_csv('results_summary.csv', index=False)

print("結果摘要已儲存至 results_summary.csv")

if __name__ == "__main__":

    main()

```


classifiers

```
from sklearn.neighbors import KNeighborsClassifier

from sklearn.ensemble import RandomForestClassifier

from sklearn.svm import SVC

from sklearn.preprocessing import StandardScaler

from sklearn.pipeline import Pipeline


class BaseClassifierWrapper:

    """提供一個通用的方法來獲取模型的預測分數"""

    @staticmethod

    def _get_scores(model, X):

        """優先嘗試 decision_function，其次是 predict_proba（回傳每個類別的機率）。"""

        # 先嘗試取得原生的分數，若不行再嘗試獲取每個類別的機率

        decision_values = None

        proba_values = None

        if hasattr(model, 'decision_function'):

            try:

                decision_values = model.decision_function(X)

            except Exception:

                pass # 忽略錯誤

        if hasattr(model, 'predict_proba'):

            try:

                proba_values = model.predict_proba(X)

            except Exception:
```

```
pass # 忽略錯誤
```

```
return proba_values, decision_values
```

```
class KNeighborsClassifierWrapper(BaseClassifierWrapper):
```

```
    """KNN 分類器的封裝。"""
```

```
    def __init__(self, n_neighbors=5):
```

```
        self.model = Pipeline([
```

```
            ('scaler', StandardScaler()),
```

```
            ('knn', KNeighborsClassifier(n_neighbors=n_neighbors))
```

```
        ])
```

```
    def train(self, X_train, y_train):
```

```
        self.model.fit(X_train, y_train)
```

```
    def test(self, X_test):
```

```
        y_pred = self.model.predict(X_test)
```

```
        proba, dec = self._get_scores(self.model, X_test)
```

```
        return y_pred, proba, dec
```

```
class RandomForestClassifierWrapper(BaseClassifierWrapper):
```

```
    """Random Forest 分類器的封裝。"""
```

```
    def __init__(self, n_estimators=100, random_state=42):
```

```
        self.model = Pipeline([
```

```
            ('scaler', StandardScaler()),
```

```
            ('rf', RandomForestClassifier(n_estimators=n_estimators, random_state=random_state))
```

```
        ])
```

```
    def train(self, X_train, y_train):
```

```
self.model.fit(X_train, y_train)
```

```
def test(self, X_test):
```

```
    y_pred = self.model.predict(X_test)
```

```
    proba, dec = self._get_scores(self.model, X_test)
```

```
    return y_pred, proba, dec
```

```
class SupportVectorMachineWrapper(BaseClassifierWrapper):
```

```
    """SVM 分類器的封裝。"""
```

```
    def __init__(self, C=1.0, kernel='rbf', probability=True, random_state=42):
```

```
        # 註：probability=True 讓 SVC 能夠使用 predict_proba，但會增加訓練時間。
```

```
        self.model = Pipeline([
```

```
            ('scaler', StandardScaler()),
```

```
            ('svm', SVC(C=C, kernel=kernel, probability=probability, random_state=random_state))
```

```
        ])
```

```
    def train(self, X_train, y_train):
```

```
        self.model.fit(X_train, y_train)
```

```
    def test(self, X_test):
```

```
        y_pred = self.model.predict(X_test)
```

```
        proba, dec = self._get_scores(self.model, X_test)
```

```
        return y_pred, proba, dec
```

utils

```
import os
```

```
import pandas as pd
```

```
from sklearn.datasets import load_breast_cancer, load_digits
```

```
def load_dataset(name: str):
```

```
    """
```

根據名稱載入指定的數據集，採用本地優先策略。

Args:

name (str): 數據集名稱。可選值:

'breast_cancer', 'digits', 'banknote', 'dry_bean'

Returns:

tuple: (X, y) or (None, None) if loading fails.

X: 特徵數據 (np.ndarray)

y: 標籤 (np.ndarray)

```
    """
```

```
if name == 'breast_cancer':
```

```
    data = load_breast_cancer()
```

```
    return data.data, data.target
```

```
elif name == 'digits':
```

```
    data = load_digits()
```

```
    return data.data, data.target
```

```
elif name == 'banknote':
```

```
    local_path = 'data/data_banknote_authentication.txt'
```

```
    if os.path.exists(local_path):
```

```
        print(f'從本地路徑加載 '{name}' 數據集: {local_path}')
```

```

df = pd.read_csv(local_path, header=None)

else:

    url = 'https://archive.ics.uci.edu/ml/machine-learning-
databases/00267/data_banknote_authentication.txt'

    print(f'本地檔案未找到，嘗試從網路後備連結加載: {url}')

    try:

        df = pd.read_csv(url, header=None)

    except Exception as e:

        print(f'無法從網路讀取 banknote 數據，請手動下載至 '{local_path}'。錯誤: {e}')

        return None, None

X = df.iloc[:, :-1].values

y = df.iloc[:, -1].values

return X, y

elif name == 'dry_bean':

    # 根據建議，我們預期用戶已將解壓縮後的檔案放在 data/DryBeanDataset/ 目錄下

    local_path = 'data/DryBeanDataset/Dry_Bean_Dataset.xlsx'

    if not os.path.exists(local_path):

        print(f'錯誤: 找不到 '{local_path}'。")

        print("請確認您已手動從 Kaggle 下載數據集，並將其解壓縮後的 .xlsx 檔案放置在正
確的路徑中。")

        return None, None

    print(f'從本地路徑加載 '{name}' 數據集: {local_path}')

    df = pd.read_excel(local_path)

    X = df.iloc[:, :-1].values

    y = df.iloc[:, -1].values

```

```
return X, y
```

```
else:
```

```
    raise ValueError(f'未知的數據集名稱: {name}。請從 'breast_cancer', 'digits', 'banknote',  
'dry_bean' 中選擇。")
```

evaluation

```
import matplotlib.pyplot as plt
```

```
import seaborn as sns
```

```
import numpy as np
```

```
import os
```

```
from sklearn.metrics import confusion_matrix, roc_curve, auc
```

```
# =====
```

```
# 混淆矩陣繪圖
```

```
# =====
```

```
def plot_confusion_matrix(y_true, y_pred, title: str, save_path: str):
```

```
    """
```

```
    計算並繪製混淆矩陣，並將其儲存為圖片檔案。
```

```
    支援任意類別數量與格式（含字串標籤）。
```

```
    """
```

```
    os.makedirs(os.path.dirname(save_path), exist_ok=True)
```

```
    labels = np.unique(np.concatenate((y_true, y_pred)))
```

```
    cm = confusion_matrix(y_true, y_pred, labels=labels)
```

```
    fig, ax = plt.subplots(figsize=(8, 6))
```

```
    sns.heatmap(cm, cmap="Blues", cbar=True, ax=ax,
```

```
xticklabels=labels, yticklabels=labels)
```

```
# === 手動標註每格 ===
```

```
for i in range(cm.shape[0]):
```

```
    for j in range(cm.shape[1]):
```

```
        value = cm[i, j]
```

```
        color = "white" if value > cm.max() / 2 else "black"
```

```
        ax.text(j + 0.5, i + 0.5, f'{value:d}',
```

```
                ha="center", va="center", color=color, fontsize=12)
```

```
# === 額外資訊 ===
```

```
acc = np.trace(cm) / np.sum(cm)
```

```
total = np.sum(cm)
```

```
ax.set_title(f'{title}\nAccuracy = {acc:.3f}, Total = {total}')
```

```
ax.set_ylabel("Actual Label")
```

```
ax.set_xlabel("Predicted Label")
```

```
plt.tight_layout()
```

```
plt.savefig(save_path, dpi=300, bbox_inches="tight")
```

```
plt.close()
```

```
print(f'混淆矩陣已儲存至: {save_path}')
```

```
# =====
```

```
# ROC 曲線繪圖
```

```
# =====
```

```
def plot_roc_curves(results, title: str, save_path: str):
```

```
"""
```

在同一張圖上繪製多個分類器的 ROC 曲線，並儲存為檔案。

results 格式為 [(y_true, y_score, name), ...]

```
"""
```

```
os.makedirs(os.path.dirname(save_path), exist_ok=True)
```

```
plt.figure(figsize=(10, 8))
```

```
for y_true, y_scores, name in results:
```

```
    fpr, tpr, _ = roc_curve(y_true, y_scores)
```

```
    roc_auc = auc(fpr, tpr)
```

```
    plt.plot(fpr, tpr, lw=2, label=f'{name} (AUC = {roc_auc:.4f})')
```

```
plt.plot([0, 1], [0, 1], color='gray', lw=1.5, linestyle='--')
```

```
plt.xlim([0.0, 1.0])
```

```
plt.ylim([0.0, 1.05])
```

```
plt.xlabel('False Positive Rate')
```

```
plt.ylabel('True Positive Rate')
```

```
plt.title(title)
```

```
plt.legend(loc="lower right", fontsize=10)
```

```
plt.tight_layout()
```

```
plt.savefig(save_path, dpi=300, bbox_inches="tight")
```

```
plt.close()
```

```
print(f' ROC 曲線圖已儲存至: {save_path}')
```

```
# =====
```

```
# 單一指標比較長條圖
```



```
# =====
```

```
def plot_metric_comparison(results, metric_name: str, title: str, save_path: str):
```

```
    """
```

```
    繪製不同分類器在同一指標下的比較圖。
```

```
    results = {'SVM': 0.98, 'KNN': 0.95, ...}
```

```
    """
```

```
    os.makedirs(os.path.dirname(save_path), exist_ok=True)
```

```
    names = list(results.keys())
```

```
    scores = list(results.values())
```

```
    plt.figure(figsize=(10, 6))
```

```
    bars = plt.bar(names, scores, color=['#1f77b4', '#ff7f0e', '#2ca02c'])
```

```
    plt.xlabel('Classifier')
```

```
    plt.ylabel(metric_name)
```

```
    plt.title(title)
```

```
    # 動態調整 Y 軸範圍
```

```
    min_score, max_score = min(scores), max(scores)
```

```
    if min_score == max_score:
```

```
        plt.ylim([min_score * 0.95 - 0.05, max_score * 1.05 + 0.05])
```

```
    else:
```

```
        plt.ylim([min_score - (max_score - min_score) * 0.1,
```

```
                  max_score + (max_score - min_score) * 0.1])
```

```
    for bar in bars:
```

```
        yval = bar.get_height()
```

```
plt.text(bar.get_x() + bar.get_width() / 2.0, yval, f'{yval:.4f}',
```

```
ha='center', va='bottom', fontsize=10)
```

```
plt.tight_layout()
```

```
plt.savefig(save_path, dpi=300, bbox_inches="tight")
```

```
plt.close()
```

```
print(f' {metric_name} 比較圖已儲存至: {save_path}')
```

```
# =====
```

```
# Cross-Validation 穩定性圖（新功能）
```

```
# =====
```

```
def plot_cv_stability_bar(results_dict, metric_name: str, title: str, save_path: str):
```

```
    """
```

```
    繪製不同分類器的 Cross-Validation 平均分數 ± 標準差。
```

```
    results_dict = {
```

```
        'SVM': (mean, std),
```

```
        'KNN': (mean, std),
```

```
        ...
```

```
    }
```

```
    """
```

```
    os.makedirs(os.path.dirname(save_path), exist_ok=True)
```

```
    names = list(results_dict.keys())
```

```
    means = [v[0] for v in results_dict.values()]
```

```
    stds = [v[1] for v in results_dict.values()]
```

```
    plt.figure(figsize=(10, 6))
```

```

bars = plt.bar(names, means, yerr=stds, capsize=6,

                color=['#1f77b4', '#ff7f0e', '#2ca02c'], alpha=0.85)

plt.xlabel("Classifier")

plt.ylabel(metric_name)

plt.title(title)


for i, bar in enumerate(bars):

    plt.text(bar.get_x() + bar.get_width()/2, bar.get_height() + stds[i],

             f" {means[i]:.4f} ± {stds[i]:.4f} ", ha="center", va="bottom", fontsize=9)


plt.tight_layout()

plt.savefig(save_path, dpi=300, bbox_inches="tight")

plt.close()

print(f" {metric_name} 穩定性比較圖已儲存至: {save_path}")

```

visualize

```

from sklearn.preprocessing import LabelEncoder

from sklearn.decomposition import PCA

import matplotlib.pyplot as plt

import os

import numpy as np

from sklearn.discriminant_analysis import LinearDiscriminantAnalysis as LDA


BASE_DIR = os.path.dirname(os.path.abspath(__file__))

PLOTS_DIR = os.path.join(BASE_DIR, 'plots')

os.makedirs(PLOTS_DIR, exist_ok=True)

```

```

def visualize_pca(X, y, dataset_name):

    """將資料降維至 2D 並以 PCA 可視化，圖片儲存在 plots 資料夾中"""

    pca = PCA(n_components=2)

    X_pca = pca.fit_transform(X)

    # === 新增：將字串標籤轉成整數 ===

    if y.dtype == object or isinstance(y[0], str):

        le = LabelEncoder()

        y_encoded = le.fit_transform(y)

        class_names = le.classes_

    else:

        y_encoded = y

        class_names = np.unique(y)

    plt.figure(figsize=(8, 6))

    scatter = plt.scatter(

        X_pca[:, 0], X_pca[:, 1],

        c=y_encoded, cmap='Spectral', alpha=0.7, s=30

    )

    plt.title(f"PCA Visualization - {dataset_name}")

    plt.xlabel("Principal Component 1")

    plt.ylabel("Principal Component 2")

    # 新增：顯示圖例（每個顏色對應的類別）

    handles, _ = scatter.legend_elements()

    plt.legend(handles, class_names, title="Classes", bbox_to_anchor=(1.05, 1), loc='upper left')

```

```
# 儲存圖

BASE_DIR = os.path.dirname(os.path.abspath(__file__))

save_dir = os.path.join(BASE_DIR, 'plots')

os.makedirs(save_dir, exist_ok=True)

save_path = os.path.join(save_dir, f'PCA_{dataset_name}.png')

plt.tight_layout()

plt.savefig(save_path, dpi=300, bbox_inches='tight')

plt.close()

print(f'PCA 圖已儲存至: {save_path}')
```

```
def visualize_lda(X, y, dataset_name: str):
```

```
    """
```

使用 LDA（Linear Discriminant Analysis）進行有監督降維，
並將結果以散點圖可視化，輸出至 `plots` 資料夾。

Parameters

`X : np.ndarray`

特徵矩陣

`y : np.ndarray`

標籤向量（可為數字或字串）

`dataset_name : str`

資料集名稱（將用於檔名與標題）

```
    """
```

```
# === 確保標籤是數字 ===
```

```
if y.dtype == object or isinstance(y[0], str):
```

```

le = LabelEncoder()

y_encoded = le.fit_transform(y)

class_names = le.classes_

else:

    y_encoded = y

    class_names = np.unique(y)


n_classes = len(np.unique(y_encoded))


# === LDA 降維 ===

n_components = 2 if n_classes > 2 else 1

lda = LDA(n_components=n_components)

X_lda = lda.fit_transform(X, y_encoded)


# === 畫圖 ===

plt.figure(figsize=(8, 6))

if n_components == 2:

    scatter = plt.scatter(

        X_lda[:, 0], X_lda[:, 1],

        c=y_encoded, cmap="Spectral", alpha=0.7, s=30

    )

    plt.xlabel("LDA Component 1")

    plt.ylabel("LDA Component 2")

else:

    scatter = plt.scatter(

        X_lda[:, 0], np.zeros_like(X_lda),

        c=y_encoded, cmap="Spectral", alpha=0.7, s=30

```

```

    )

    plt.xlabel("LDA Component 1")

    plt.yticks([])


plt.title(f'LDA Visualization - {dataset_name}')


# 圖例

handles, _ = scatter.legend_elements()

plt.legend(handles, class_names, title="Classes",

           bbox_to_anchor=(1.05, 1), loc='upper left')


# === 儲存圖像 ===

BASE_DIR = os.path.dirname(os.path.abspath(__file__))

save_dir = os.path.join(BASE_DIR, 'plots')

os.makedirs(save_dir, exist_ok=True)

save_path = os.path.join(save_dir, f'LDA_{dataset_name}.png')


plt.tight_layout()

plt.savefig(save_path, dpi=300, bbox_inches='tight')

plt.close()


print(f'LDA 圖已儲存至: {save_path}')
```

Requirements

contourpy==1.3.3

cycler==0.12.1

et_xmlfile==2.0.0

fonttools==4.60.1

joblib==1.5.2

kiwisolver==1.4.9

matplotlib==3.10.6

numpy==2.3.3

openpyxl==3.1.5

packaging==25.0

pandas==2.3.3

pillow==11.3.0

pyparsing==3.2.5

python-dateutil==2.9.0.post0

pytz==2025.2

scikit-learn==1.7.2

scipy==1.16.2

seaborn==0.13.2

six==1.17.0

tabulate==0.9.0

threadpoolctl==3.6.0

tzdata==2025.2

GitHub

GitHub : <https://github.com/megrez33281/classifiers-experiment>